Siniestralidad vial en Bogotá

Informe de modelos y avance del producto analítico

MIAD · Despliegue de Soluciones Analíticas
Proyecto Entrega 2 · Versión 0.2
8 de noviembre de 2026 · Bogotá

Equipo y responsabilidades

Integrante	Responsabilidad de coordinación
Andrés · AndruTP	EDA, MLflow en EC2, repositorio y reproducibilidad
Jairo · jairoeduardohortuab	Maqueta, visualización y tablero funcional
José · Josepfcalderon	Validación temporal, modelos e integración del informe

Las responsabilidades organizan el trabajo. La autoría de cada cambio se acredita en el reporte de equipo independiente con commits, pull requests y revisión cruzada.

Resultado principal

El ensamble relativo entrenado con 2019–2023 obtiene MAE 6,7000 en validación 2024, frente a 7,0146 de la media móvil de 12 meses. La mejora es 4,4846 % y no cumple la meta inicial de 10 %. La prueba de 2025 está reservada. Se presentan evidencias de los experimentos registrados en MLflow, la infraestructura AWS EC2 y el tablero de control desarrollado en HTML, conservando las consideraciones sobre la integración predictiva.

Control de versiones

Versión y fecha	Contenido	Consolidación y revisión
0.2 · 08/11/2026	Actualización de resultados, evidencias MLflow, tablero de control y trazabilidad de contribuciones.	José consolida; revisión del equipo aprobada.

Ubicación prevista en GitHub: entregas/entrega_2/Informe_Entrega_2_v0.2.docx
Repositorio: https://github.com/AndruTP/DSA-Siniestralidad-Bogota

1. Contextualización y cambios respecto a Entrega 1

La siniestralidad vial afecta la vida, la salud y la movilidad de Bogotá. El proyecto estima el número mensual de siniestros registrados con heridos o muertos por localidad para apoyar a analistas de seguridad vial en la revisión de prioridades preventivas. El objetivo cuenta siniestros, no personas lesionadas o fallecidas.

Pregunta de negocio y alcance

¿Cuántos siniestros con víctimas se esperan el próximo mes en cada localidad y qué cambios frente al comportamiento histórico justifican una revisión de prioridades territoriales? El horizonte es un mes adelante. La unidad de análisis es localidad–mes. Se modelan 19 localidades; Sumapaz permanece en la descripción histórica y se excluye provisionalmente del modelo por su escasa frecuencia.

La priorización por volumen favorece territorios grandes y no equivale a riesgo por habitante o por viaje. El pronóstico debe complementar el volumen histórico con cambios esperados; no sustenta decisiones automáticas ni permite atribuir efectos a intervenciones.

Datos empleados

La fuente es ACCIDENTE de la Secretaría Distrital de Movilidad. La versión ampliada del EDA caracteriza 906.664 registros y 23 columnas. El panel 2016–2025 comprende 19 localidades y 2.280 filas; tras exigir 12 meses de historia quedan 2.052 observaciones de enero de 2017 a diciembre de 2025 y 15 columnas. Se agregan CON

HERIDOS y CON MUERTOS; SOLO DAÑOS se excluye del objetivo por la discontinuidad de registro observada desde octubre de 2022. Los meses de 2026 no integran el panel.

Cambios y respuesta a la retroalimentación

Se pasa del EDA y la maqueta a modelos supervisados y comparación temporal. Se estudia la permanencia del ranking, se caracterizan cambios de nivel y estacionalidad, y se comparan ventanas de entrenamiento. El notebook registra 83 pares de meses en 2017–2023: correlación de rangos media 0,897 y coincidencia media de 4,19 de las cinco primeras localidades. Un ranking persistente tiene utilidad limitada para detectar cambios emergentes.

La retroalimentación solicita explicar qué decisión cambia con el pronóstico, aclarar granularidad y actualización de datos, simplificar el tablero y documentar aportes individuales. Se propone mostrar variación frente al mismo mes del año anterior y separar observado de pronosticado. La actualización periódica y el reentrenamiento siguen pendientes; deben conservar fecha de extracción, versión y huella de datos.

2. Metodología y protocolo de evaluación

Preparación y prevención de información futura

El EDA ampliado ordena por localidad y periodo. Genera rezagos de 1, 3, 6 y 12 meses y medias móviles de 3, 6 y 12 meses con desplazamiento de un mes. Las comprobaciones guardadas confirman 2.052 filas, 19 localidades, ausencia de nulos y duplicados localidad–mes, y consistencia del rezago de un mes. Las combinaciones sin registros se tratan provisionalmente como ceros; debe validarse su cobertura.

Conjunto	Periodo	Observaciones y finalidad
Entrenamiento	2017–2023	1.596 · ajuste inicial
Validación	2024	228 · comparación y selección preliminar
Prueba final	2025	228 · reservadas; bloque desactivado

La evaluación es mensual sucesiva de un paso adelante. Los conteos reales de meses anteriores de 2024 pueden alimentar los rezagos posteriores; no es un pronóstico de doce meses emitido en diciembre de 2023. Las transformaciones aprendidas se ajustan con entrenamiento. No se usa partición aleatoria de las filas para la comparación principal.

Variables y modelos de referencia

Los 13 predictores iniciales son localidad, mes, año, seno y coseno del mes, cuatro rezagos, tres medias móviles y el indicador 2020–2021. La localidad se codifica dentro del pipeline. PERIODO se conserva para orden y control; SINIESTROS es la variable objetivo. La referencia común es MEDIA_MOVIL_12 del mismo mes evaluado, calculada solo con historia anterior.

Se añaden EWM_6 desplazada e índice estacional de ciudad del mismo mes en años anteriores. Los modelos relativos transforman siete indicadores históricos mediante log(1+x) − log(1+MM12), y agregan calendario cíclico, estacionalidad e indicador 2020–2021. La localidad no entra explícitamente en esta matriz; su nivel se incorpora mediante la MM12 territorial.

Métricas y criterio de éxito

MAE = promedio de |predicción − observado|, en siniestros por localidad–mes; es la métrica principal. RMSE = raíz del promedio de errores cuadrados y penaliza errores grandes. Sesgo = promedio de (predicción − observado); positivo indica sobreestimación. Mejora = 100 × (MAE_base − MAE_modelo) / MAE_base. Un valor negativo indica deterioro.

La meta inicial es reducir al menos 10 % el MAE de la referencia: 0,90 × 7,0146 ≈ 6,3132. Se conserva sin redefinirla tras ver resultados. Las cifras se verificaron contra código y salidas guardadas de los notebooks; no constituyen una nueva ejecución integral del entrenamiento.

3. Modelos desarrollados y resultados verificados

Especificaciones comparadas

Gradient Boosting inicial: HistGradientBoostingRegressor con pérdida Poisson, 250 iteraciones, tasa 0,05, 15 hojas, mínimo 15 muestras por hoja, regularización L2 de 1, early_stopping=False y semilla 42. Se repite con ventana 2021–2023 (684 filas). NB2 original converge, con dispersión 0,0413; NB2 revisada incorpora offset MM12, rezagos logarítmicos relativos y omite año como tendencia lineal; converge con dispersión 0,03367.

ModeloOffset estima la razón SINIESTROS / max(MM12,1), pondera el ajuste por ese nivel y reconstruye el conteo al predecir. Combina PoissonRegressor (alpha=0,001, max_iter=5000) e HistGradientBoosting Poisson (300 iteraciones, tasa 0,03, 8 hojas, mínimo 30 muestras por hoja, semilla 42). El ensamble promedia ambas razones con igual peso. Se prueban inicios 2017, 2019 y 2021: nueve configuraciones relativas.

Validación común sobre 228 observaciones de 2024

Modelo y entrenamiento	MAE	RMSE	Sesgo
Media móvil 12 meses	7,0146	9,5464	−0,2376
HGB Poisson 2017–2023	7,1921	10,1549	−0,1126
HGB Poisson 2021–2023	7,3058	9,9658	−0,1946
NB2 original 2017–2023	8,7144	13,5363	−5,3913
NB2 revisada 2017–2023	7,3664	9,9919	1,2144
Offset ensamble 2019–2023	6,7000	9,3664	−0,2392
Offset ensamble 2021–2023	6,7931	9,3401	0,6701
Offset HGB 2019–2023	6,8186	9,5921	−0,0807
Offset ensamble 2017–2023	6,8311	9,4600	0,3869

Fuentes: notebook de entrenamiento, celdas posicionales 23, 26, 47, 50 y 53. NB2 revisada se incorpora desde su salida propia, pues la tabla consolidada de la celda 53 no la incluye. Las cinco configuraciones relativas restantes tienen MAE entre 6,9028 y 7,0538 (celda 47). Ninguna alternativa alcanza la meta.

El candidato por MAE es el ensamble relativo 2019–2023 (1.140 filas de ajuste), con mejora 4,4846 %. La selección por RMSE favorecería al ensamble 2021–2023; se mantiene MAE como criterio declarado. La reducción respecto a la referencia es modesta y no demuestra superioridad estadística.

4. Análisis de errores y estabilidad temporal

Diferencias territoriales y cambios de distribución

El HGB inicial supera la referencia en 5 de 19 localidades. Kennedy tiene MAE 17,07; Suba, 8,92 frente a 12,65 de la referencia. Engativá presenta sesgo +6,35 y Usaquén −5,13. Estos diagnósticos pertenecen al modelo inicial y no deben atribuirse al ensamble seleccionado. La desagregación territorial del candidato queda pendiente de consolidación.

El promedio mensual agregado pasa de 1.889,58 siniestros en 2017–2019 a 1.196,62 en 2020–2021 y 1.078,92 en 2022–2023; en validación 2024 es 1.081,33. El coeficiente de variación mensual es 31,03 % en 2020–2021 y 6,16 % en 2022–2023. Estas diferencias justifican contrastar periodos de ajuste; no prueban causalidad ni estabilidad futura.

Ventanas expansivas del ensamble relativo

Inicio	Año evaluado	MAE modelo	MAE MM12	Mejora %
2017	2021	10,7522	16,8798	36,3014
2017	2022	6,8478	6,7047	−2,1343
2017	2023	7,1279	6,9130	−3,1078
2017	2024	6,8311	7,0146	2,6168
2019	2021	10,8556	16,8798	35,6884
2019	2022	11,4707	6,7047	−71,0855
2019	2023	7,2678	6,9130	−5,1319
2019	2024	6,7000	7,0146	4,4846

Fuente: celda 65. Cada evaluación entrena hasta el año previo. El desempeño cambia de signo y es sensible al inicio de la historia, especialmente en 2022. La configuración fue seleccionada con 2024; estas ventanas son un diagnóstico complementario, no una validación anidada independiente.

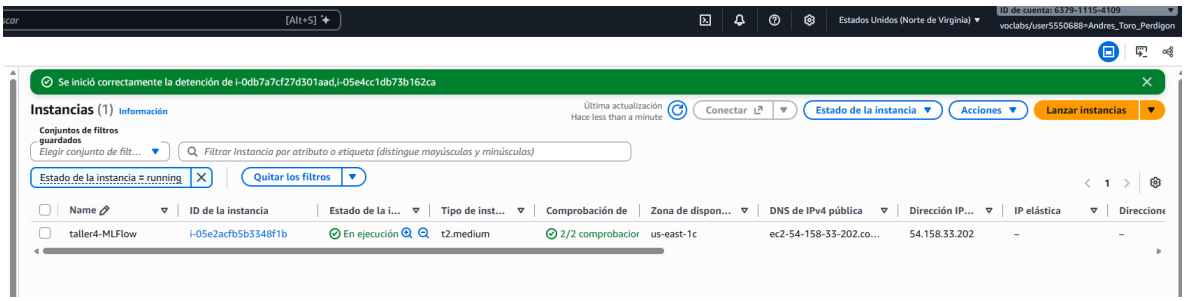
Consistencia de cifras y reserva de prueba

La tabla de resultados utiliza las salidas guardadas del notebook. Para el ensamble 2019–2023, estas muestran un MAE de 6,7000, un RMSE de 9,3664 y una mejora del 4,4846 %. La corrida registrada en MLflow que aparece en la captura reporta un MAE de 6,7123, un RMSE de 9,2996 y una mejora del 4,3099 %. La causa de la diferencia queda por verificar. En ambos resultados, el ensamble mejora frente a la media móvil de 12 meses y queda por debajo de la meta del 10 %.

2025 permanece sin evaluar en el bloque final. Sin embargo, el EDA previo ya describe referencias de 2025; por ello la reserva es operativa dentro del notebook actual y no implica desconocimiento absoluto de ese año. Antes de la prueba, congelar configuración, registrar decisión y reentrenar hasta 2024 con la ventana equivalente.

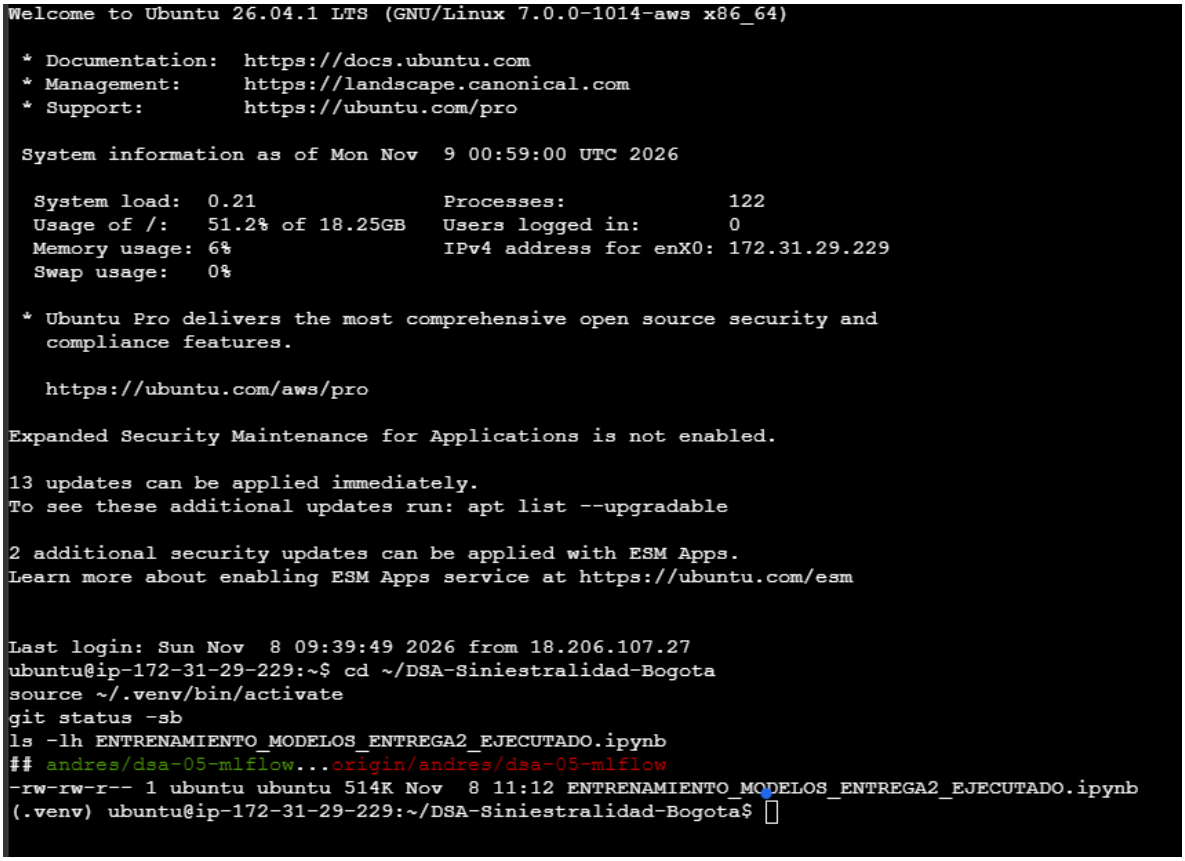
5. Infraestructura / Despliegue

Se desplegó una instancia EC2 en AWS para soportar la ejecución del proyecto y la publicación de servicios de apoyo. La instancia utilizada fue una máquina Ubuntu en estado activo, con IP pública habilitada, sobre la cual se alojaron los componentes necesarios para consulta de experimentos y visualización de resultados.



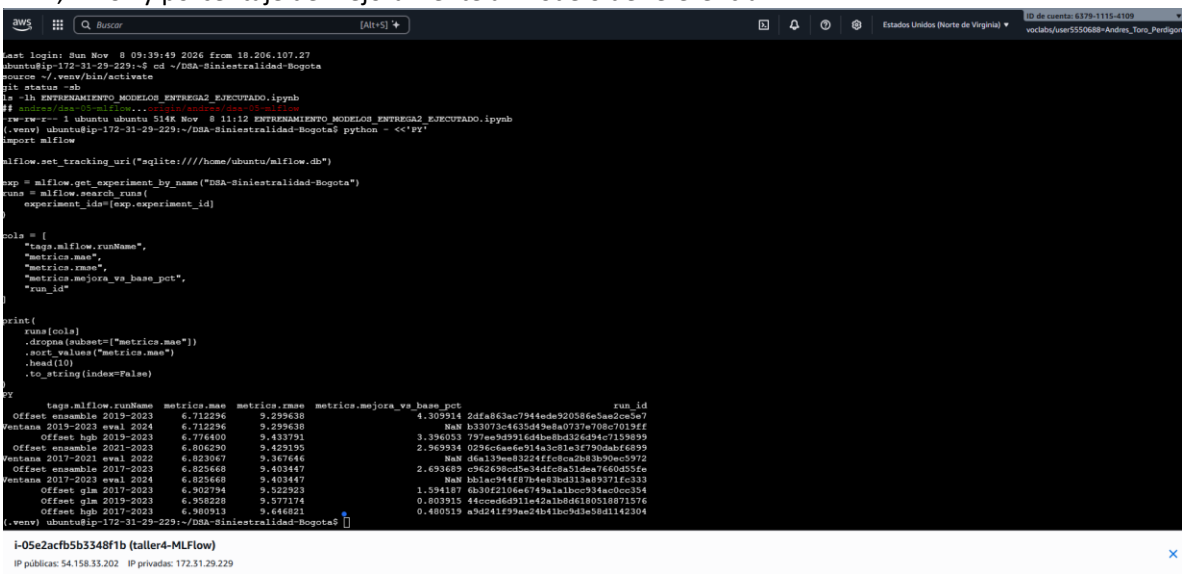
Terminal Ubuntu

Desde la instancia EC2 se verificó la disponibilidad del repositorio, el entorno de Python y el notebook ejecutado, documentando el entorno utilizado para el desarrollo del proyecto.



Terminal con la consulta de MLflow

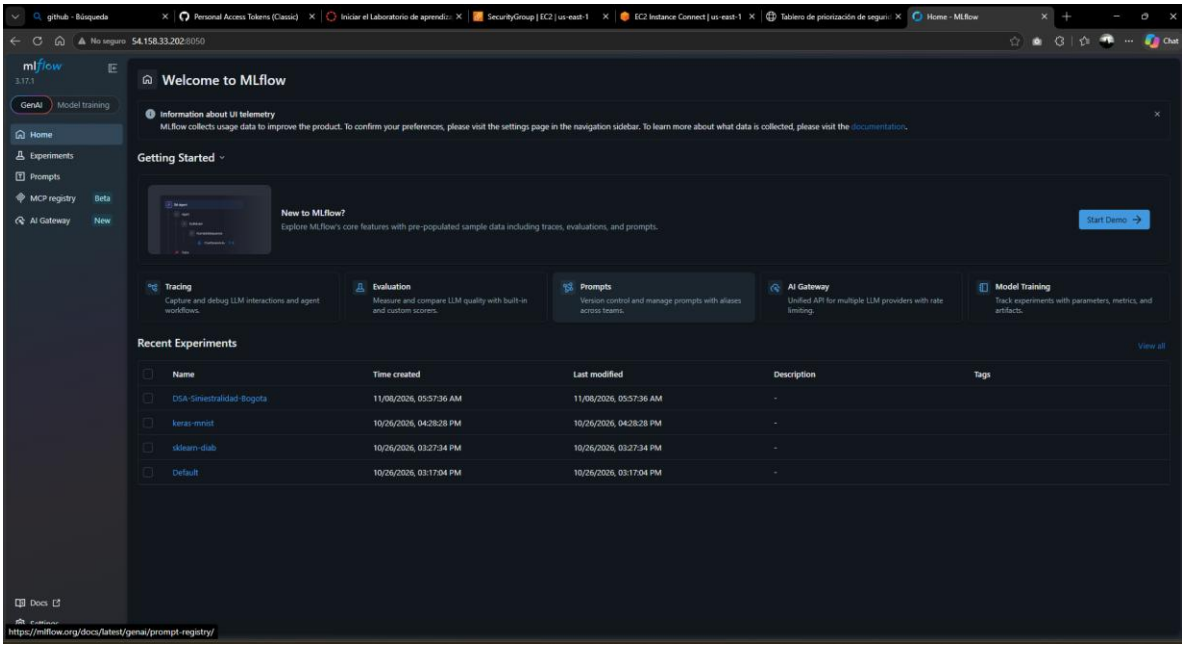
Desde la terminal se consultaron las ejecuciones registradas en MLflow y sus métricas de evaluación, incluyendo MAE, RMSE y porcentaje de mejora frente al modelo de referencia.



6. MLflow en EC2 y Tablero de control

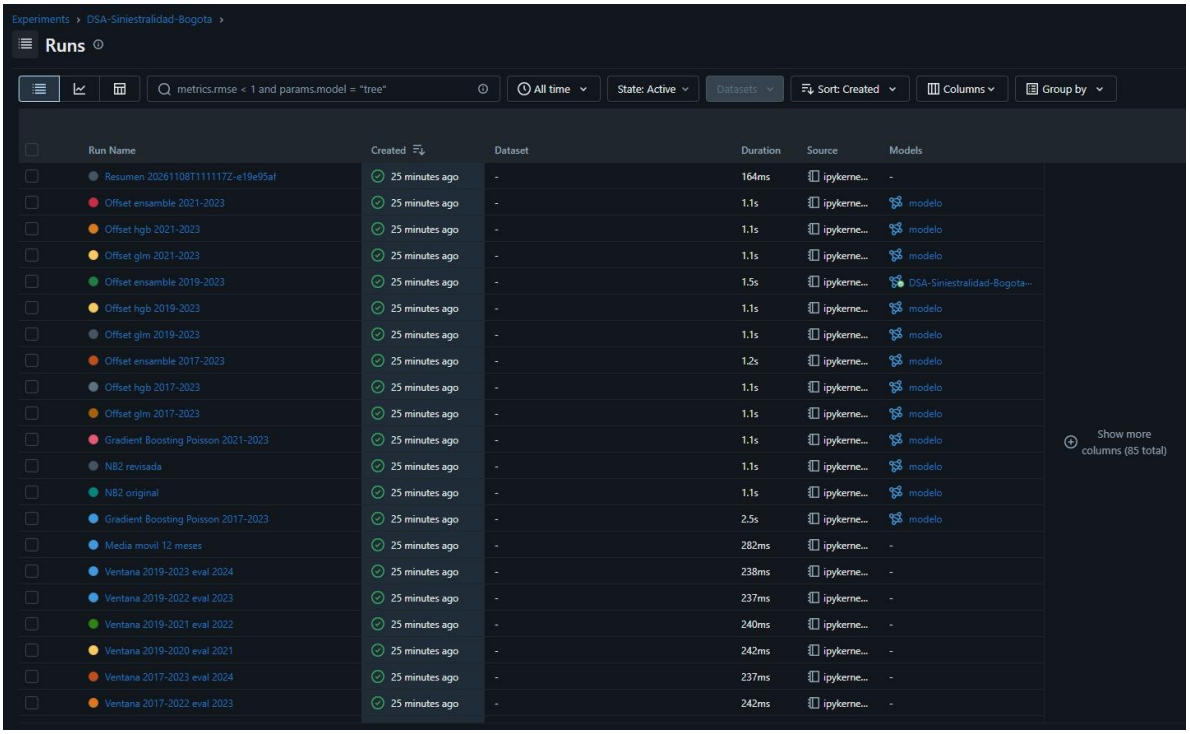
MLflow Home

Se documentó la ejecución de MLflow sobre una instancia EC2 de AWS mediante capturas de la infraestructura, la consola Ubuntu y la interfaz de experimentos. Se registraron distintas configuraciones de modelos y sus métricas, permitiendo consultar los resultados y mantener la trazabilidad experimental.



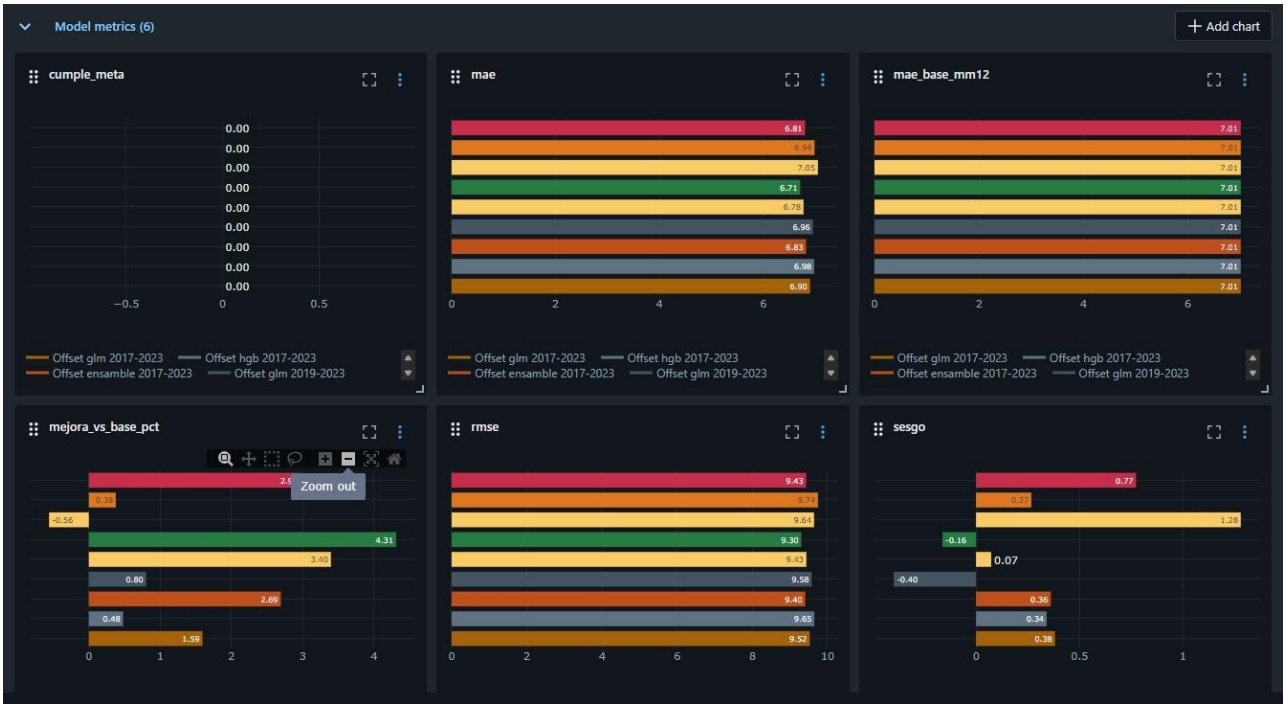
MLflow en AWS EC2 – DSA 05

Se cuenta con evidencias de experimentos registrados en MLflow, incluyendo diferentes configuraciones de modelos, métricas de evaluación y resultados comparativos. Las ejecuciones permiten consultar el desempeño mediante indicadores como MAE, RMSE y sesgo.



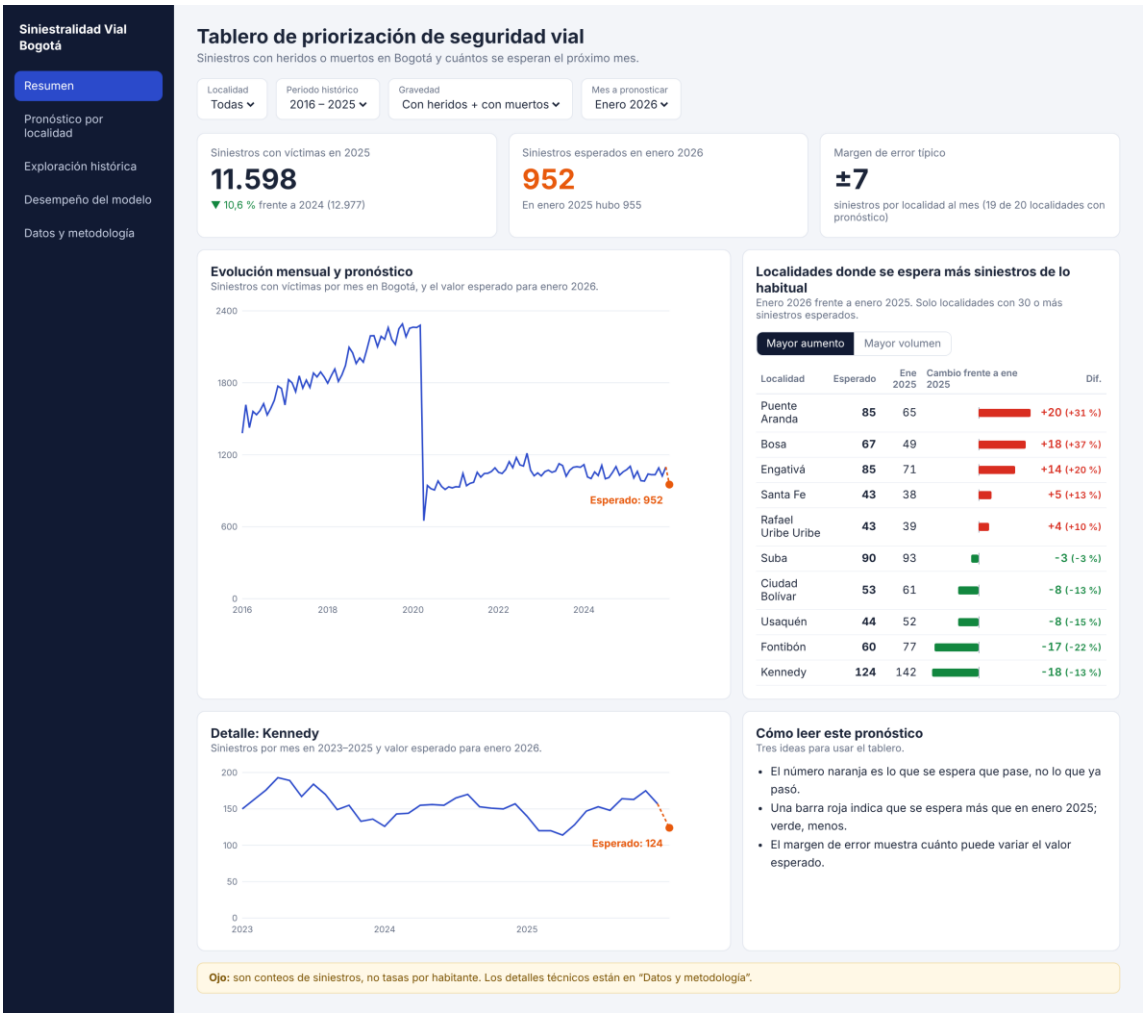
Panel de métricas de MLflow

El panel de métricas de MLflow permite comparar el desempeño de los modelos registrados mediante MAE, RMSE, sesgo y porcentaje de mejora frente al modelo de referencia, facilitando la revisión de las configuraciones evaluadas.



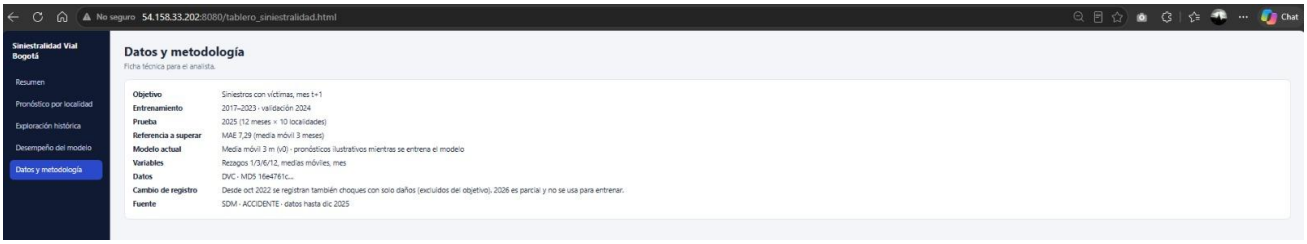
Tablero HTML publicado

El tablero HTML publicado en AWS EC2 permite consultar indicadores históricos, tendencias y comparaciones por localidad. La versión capturada presenta pronósticos ilustrativos asociados a una media móvil de 3 meses. Su ficha técnica menciona 10 localidades para la prueba, mientras que la evaluación documentada en este informe utiliza una media móvil de 12 meses como referencia y reserva la prueba de 2025 para 19 localidades. La incorporación de las predicciones del ensamble seleccionado al tablero queda pendiente.



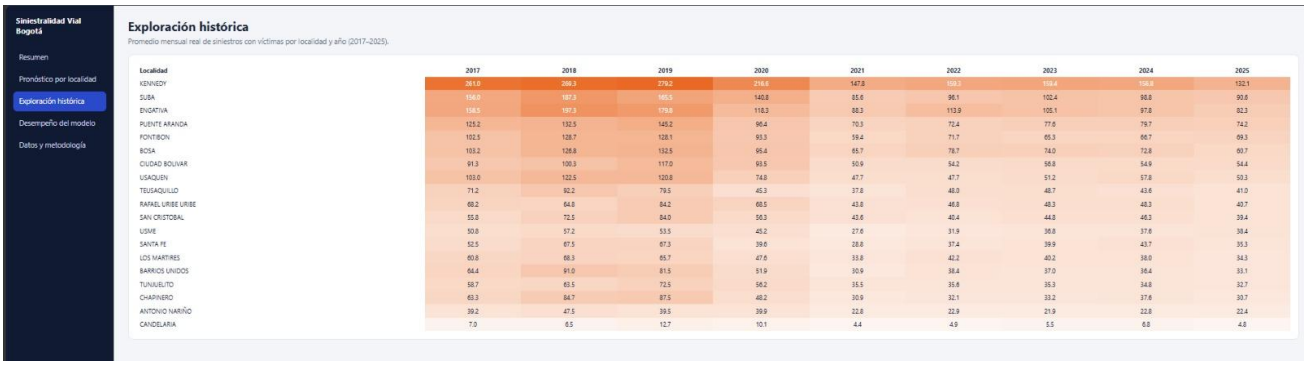
Vista de Datos y metodología

El tablero incorpora una sección metodológica que resume el objetivo analítico, la partición temporal del conjunto de datos, la referencia de comparación, las variables empleadas y la fuente de información utilizada en el proyecto.



Vista Exploración histórica

También se incluye una vista de exploración histórica que permite comparar el promedio mensual de siniestros con víctimas por localidad y año, facilitando una lectura territorial del comportamiento del fenómeno.



Funcionalidad	Estado de evidencia
Filtros de localidad, periodo y gravedad	Interfaz disponible; Filtros verificados en el tablero HTML.
Tendencia histórica y pronóstico	Visualización implementada; Pronóstico ilustrativo basado en una media móvil de 3 meses
Comparación por localidad	Visualización disponible en el tablero
Datos históricos y pronóstico ilustrativo diferenciados en la gráfica	Presentación visual disponible; consistencia por verificar

No publicar intervalos como si fueran calculados: requieren un método y evaluación de cobertura. Las cifras ilustrativas de la maqueta no son resultados del modelo. La solución global contempla modelos empaquetados, API, tablero y Docker; su integración operativa no queda acreditada por los notebooks de esta versión.

Criterio de cierre

Se incorporaron evidencias de la ejecución de MLflow en EC2 y del tablero publicado, mientras que la reproducibilidad y la integración predictiva se documentan de acuerdo con las validaciones disponibles.

7. Conclusiones y trazabilidad del trabajo

1. La formulación relativa reduce el MAE frente a MM12 en validación 2024, pero la mejora de 4,4846 % no cumple la meta de 10 %. El ensamble 2019–2023 es candidato preliminar y no modelo final validado en 2025.

2. Los errores territoriales y la variabilidad entre ventanas impiden generalizar el resultado de un único año. Deben consolidarse los errores del candidato por localidad y documentarse las condiciones de uso antes de servir inferencias.

3. El producto puede aportar una lectura de cambios esperados además del ranking por volumen. No estima tasas de riesgo ni demuestra que una intervención reduzca siniestros. La calidad de cobertura, la exclusión de Sumapaz y la disponibilidad de historia limitan el alcance.

4. Se dispone de evidencias de los experimentos registrados en MLflow y de un tablero de control desarrollado en HTML, los cuales representan avances en el despliegue de la solución analítica.

Matriz de trazabilidad DSA 01 a DSA 08

Issue	Responsable	Sección y condición por completar
DSA-01 · Correcciones EDA	Andrés	1–2 y evidencias · validar ceros, cobertura y cifras
DSA-02 · Validación temporal	José	Validación temporal desarrollada, PR fusionado; evidencia registrada en GitHub.
DSA-03 · Ajuste del mockup	Jairo	Mockup ajustado según retroalimentación, PR #11 fusionado.
DSA-04 · Modelos y métricas	José	Métricas corregidas, PR #13 aprobado y fusionado
DSA-05 · MLflow en EC2	Andrés	Experimentos MLflow registrados en AWS EC2, con evidencias de instancia, terminal, métricas y ejecuciones.
DSA-06 · Tablero funcional	Jairo	Tablero HTML desarrollado, PR #12 fusionado; validación predictiva
DSA-07 · Repositorio y pruebas	Andrés	Dependencias, reproducción y evidencia de aportes
DSA-08 · Informe y evidencias	José	Informe v0.2 en consolidación; revisión y cierre

Los códigos DSA identifican actividades; no son números de issue de GitHub ni certifican su cierre. Cada integrante aporta cambios reales con su identidad, enlaza commit y PR al issue correspondiente y solicita revisión cruzada. El responsable reúne los soportes antes de cerrar.

Publicación prevista: El informe v0.2 y el reporte de trabajo en equipo se incorporarán mediante la rama dsa-08-informe-entrega2, conservando el historial de contribuciones y solicitando la revisión correspondiente antes del cierre.

Se implementó un entorno de experimentación con MLflow en AWS EC2 y se publicó el tablero HTML del proyecto, incorporando visualizaciones históricas y herramientas de consulta. Las evidencias permiten documentar el avance técnico, mientras que la integración predictiva y la reproducibilidad completa deben evaluarse de acuerdo con las pruebas correspondientes.

8. Fuentes y listado de evidencias

Fuentes y localizadores

F1 · dsa_proy_e2.pdf, páginas 1–5: alcance, modelos, MLflow, tablero, máximo 10 páginas, soporte EC2 y reporte de equipo independiente de máximo una página.

F2 · Retroalimentación Coursera Entrega 1, captura PDF del 06/11/2026 a las 21:12:45, páginas 1–2: utilidad incremental del pronóstico, volumen frente a riesgo, granularidad y actualización, estabilidad del ranking, cambio de distribución, simplificación de maqueta y aportes individuales.

F3 · SINIESTROS_BOGOTA.ipynb (versión inicial de 19 celdas) y copia ampliada SINIESTROS_BOGOTA (1).ipynb (46 celdas). La ampliada sustenta el panel y sus controles, celdas 43–45. Las cifras de esta versión corresponden al EDA ampliado.

F4 · ENTRENAMIENTO_MODELOS_ENTREGA2.ipynb (76 celdas): 4 y 8, datos y particiones; 14, 20, 26, 47 y 50, modelos; 17, 32 y 38, diagnósticos; 23, 47, 50 y 53, métricas; 65, ventanas; 69 y 72, preparación del registro de experimentos en MLflow; 75, prueba final desactivada. Las evidencias de ejecución de MLflow se presentan en la sección 6. La numeración es posicional desde uno, no contador de ejecución.

Evidencias disponibles y requeridas

ID	Soporte y estado	Issue
E01	EDA ampliado: panel y controles guardados disponibles	01–02
E02	Notebook de entrenamiento: código y salidas 2024 disponibles	04
E03	CSV de métricas y predicciones: el código prevé exportación; adjuntar y versionar archivos	04
E04	Capturas de ejecuciones y métricas de MLflow incorporadas	05
E05	Capturas de instancia EC2, consola Ubuntu y acceso a MLflow incorporadas	05
E06	Tablero HTML y captura incorporados; PR #11 y #12	03–06
E07	Dependencias y ejecución desde entorno limpio	07
E08	PR #13 aprobado y fusionado; PR de DSA-02 fusionado. Enlaces y revisión documentados en el reporte de trabajo en equipo.	07–08
E09	Prueba final 2025: pendiente tras congelar selección	02–04
E10	Informe v0.2 disponible; revisión conjunta y publicación	08

Identidad del dataset cargado en F4, celda 4, SHA-256:
17277bb9603aab18c2b1e96975f1b77d899f40e85a079fa3dd3edf199da3fd34

El reporte de equipo se conserva por separado: Reporte_Trabajo_Equipo_Entrega_2_v0.2.docx. Distingue responsabilidad asignada de contribución realizada y deja campos de evidencia individual pendientes de validación.